


Egy biztosítótársaság az ügyfelek lemorzsolódását szeretné modellezni egy **döntési fa modell** segítségével.
A modell összesen **P: 3200 pozitív** esetet, azaz megtartott ügyfelet, és **N:1850 negatív**, azaz lemorzsolódott ügyfelet vizsgál.

A modellezők eddig két döntési döntési fát készítettek, mindkét esetben az **"A" attribútum** az első vizsgált szempont.
Az **1. döntési fa** ezt követően egy **"B" attribútumot** vizsgál,
a **2. döntési fa** pedig egy **"C" attribútumot** az alábbiak szerint:



1. kérdés: mennyi a információ igény a
Fa építésénél az elején? (Azaz A pontban)

$$H(A) = -\frac{3200}{5050} \cdot \log_2\left(\frac{3200}{5050}\right) - \frac{1850}{5050} \cdot \log_2\left(\frac{1850}{5050}\right) = 0,948$$

2. kérdés: A attribútum 1. értéke A1 esetén?

$$H(A1) = -\frac{214}{650} \cdot \log_2\left(\frac{214}{650}\right) - \frac{436}{650} \cdot \log_2\left(\frac{436}{650}\right) = 0,914$$

3. kérdés: A2 -nél: $H(A2) = 0$

4. kérdés: A attr. esetén a maradék entropia

$$\text{maradék} = \frac{650}{5050} \cdot 0,914 + \frac{1414}{5050} \cdot 0 + \frac{2986}{5050} \cdot 0 = \underline{0,1176}$$

5. kérdés: információ nyereség A attr. esetén: $0,948 - 0,1176 = 0,83$

6. kérdés: B esetén maradék információ igény

$$H(B1) = -\frac{182}{618} \cdot \log_2\left(\frac{182}{618}\right) - \frac{436}{618} \cdot \log_2\left(\frac{436}{618}\right) = 0,8745$$

$$H(B2) = 0$$

$$\text{maradék} = 0,8745 \cdot \frac{618}{650} = 0,8314$$

7. kérdés: B beszüntésakor információ nyereség

$$H(A1) - \text{maradék}(B) = 0,082$$

8. B1 entropiája

...

10. Feladat: C nyereség

$$H(C1) = 0,914$$

$$H(C2) = 0$$

$$\text{maradék}(C) = \frac{650}{650} \cdot 0,914 + 0 \cdot 0 = 0,914$$

$$\text{nyereség} = H(A1) - \text{maradék}(C) = 0$$