

Egy robotporszívó ágens **időbeli különbség (IK)** alapú **Q-tanulással** határozza meg az optimális eljárásmodot. Környezete három állapotból áll: **s1, s2, s3**, mindegyikben két cselekvést lehet alkalmazni **a1** és **a2**. A **tanulási tényező (bátorsági faktor) α** : 0.8 és a **leszámoztási tényező γ** : 0.6

A Q értékek táblázata:

	a1	a2
s1	7.4	0
s2	1.1	4
s3	0	5.2

A robot a következő esetekkel szembesül:

(1.) Kiindulás = s1, Cselekvés =a1, Vége= s3, Jutalom= 5.

(2.) Kiindulás = s3, Cselekvés =a1, Vége= s2, Jutalom= -10.

(3.) Kiindulás = s2, Cselekvés =a2, Vége= s3, Jutalom= 5.

(4.) Kiindulás = s3, Cselekvés =a1, Vége= s3, Jutalom= 10.

Frissítse futamonként ennek megfelelően a Q-érték táblázatot!

Adja meg a módosított **Q(s,a)** értéket az **(1.) esetet** követően!

Answer:

α = tanulási tényező

γ = leszámoztási tényező

S = hannot

a = mit

s' = hova

r = jutalom

$Q_{új}(s,a) = (1 - \alpha) \cdot Q_{régi}(s,a) + \alpha (r + \gamma \cdot \max_{a'} Q(s',a'))$

1. lépés: $Q_{régi} = Q(s_1,a_1) = 7,4$

s3-ból a legjobb akció

$Q_{új}(s,a) = (1 - 0,8) \cdot 7,4 + 0,8 \cdot (5 + 0,6 \cdot 5,4) = 7,976$

2. lépés $s_1,a_1 = 7,976$

$Q_{új}(s,a) = (1 - 0,8) \cdot 0 + 0,8 \cdot (-10 + 0,6 \cdot 4) = -6,08$

3. lépés $s_3,a_1 = -6,08$

$Q_{új}(s,a) = (1 - 0,8) \cdot 4 + 0,8 \cdot (5 + 0,6 \cdot 5,2) = 7,296$